

# Bao cao hoan chinh RQ2 SHAP LIME

*Đánh giá chất lượng lời giải thích của XGBoost trên CSE CIC IDS2018*

Kết luận chính của RQ2 là: trên cohort ghép cặp 1.339 flow, SHAP và LIME không thường xuyên chọn cùng Top 5 feature; SHAP có Domain Precision và faithfulness cao hơn LIME trong các phép đo đã chọn. LIME chạy đúng quy trình nhưng Local  $R^2$  thấp, nên chỉ được dùng như phương pháp đối chứng cục bộ chứ không phải căn cứ chính để kết luận nguyên nhân dự đoán của XGBoost.

## 1 Cau hoi nghiien cuu va cau tra loi

| Sub RQ | Câu hỏi                                                                         | Kết quả chính                                                            |
|--------|---------------------------------------------------------------------------------|--------------------------------------------------------------------------|
| 2.1    |                                                                                 |                                                                          |
|        | SHAP và LIME có chọn các feature giống nhau không?                              |                                                                          |
|        |                                                                                 | Jaccard at 5 = 0,213. Mức giống nhau Top 5 thấp - trung bình.            |
| 2.2    |                                                                                 |                                                                          |
|        | Feature quan trọng có phù hợp tín hiệu được kỳ vọng theo cơ chế tấn công không? |                                                                          |
|        |                                                                                 | Domain Precision at 5: SHAP = 0,187; LIME = 0,111. Cả hai thấp.          |
| 2.3    |                                                                                 |                                                                          |
|        | Lời giải thích có ổn định và bền vững không?                                    |                                                                          |
|        |                                                                                 | LIME: Local $R^2$ median = 0,068; stability median Jaccard at 5 = 0,415. |
| 2.4    |                                                                                 |                                                                          |
|        | Feature được chọn có thực sự ảnh hưởng đến quyết định model không?              |                                                                          |
|        |                                                                                 | Faithfulness at k = 5: SHAP = 95,74%; LIME = 90,44%.                     |

Bốn chỉ số trên đo bốn khía cạnh khác nhau. Không được cộng, trung bình hay diễn giải chúng thành một tỷ lệ duy nhất như "RQ2 đúng X phần trăm".

## 2 Phạm vi và tình tại lap

Báo cáo hợp nhất ba nhóm bằng chứng: (i) SHAP global đã tính trên toàn bộ test set 700.000 flow, (ii) SHAP per-flow và LIME per-flow trên cohort ghép cặp, và (iii) các script đánh giá agreement, domain, stability robustness và faithfulness. Các so sánh trực tiếp SHAP - LIME chỉ dùng cohort ghép cặp.

| Thành phần | Thiết lập đã khóa                                                    | Lý do |
|------------|----------------------------------------------------------------------|-------|
| Model      |                                                                      |       |
|            | XGBoost 15 lớp, 100 cây, max depth 8, learning rate 0,08, 78 feature |       |

|                 |                                                                                         |                                                                               |
|-----------------|-----------------------------------------------------------------------------------------|-------------------------------------------------------------------------------|
|                 |                                                                                         | Cùng model đã chọn trong RQ1.                                                 |
| Cohort ghép cặp |                                                                                         |                                                                               |
|                 | 1.339 flow dự đoán đúng, seed 42, tối đa 100 flow mỗi lớp                               |                                                                               |
|                 |                                                                                         | Đảm bảo SHAP và LIME giải thích đúng cùng sample và cùng output.              |
| Lớp hiếm        |                                                                                         |                                                                               |
|                 | Brute Force XSS: 44 flow; SQL Injection: 9 flow                                         |                                                                               |
|                 |                                                                                         | Giữ toàn bộ flow đúng có sẵn. Kết luận theo hai lớp này chỉ có tính minh họa. |
| SHAP            |                                                                                         |                                                                               |
|                 | TreeExplainer, raw margin, tree path dependent, không approximate                       |                                                                               |
|                 |                                                                                         | Phù hợp trực tiếp với XGBoost; kiểm tra additivity.                           |
| LIME            |                                                                                         |                                                                               |
|                 | Background 8.002 flow; 5.000 sample per flow; kernel width 6,624; discretize continuous |                                                                               |
|                 |                                                                                         | Fit Ridge surrogate cục bộ để giải thích predicted label.                     |

Cohort chỉ giữ flow dự đoán đúng để đối chiếu knowledge domain theo nhãn lớp không bị lẫn với lỗi dự đoán. Điều này không có nghĩa model không cần giải thích flow sai. Error cohort tồn tại để làm case study riêng, nhưng không được trộn vào trung bình chính của RQ2.

### 3 Phương pháp và các chỉ số

| Chỉ số                | Công thức hoặc ý tưởng                                               | Cách diễn giải đúng                                                                          |
|-----------------------|----------------------------------------------------------------------|----------------------------------------------------------------------------------------------|
| Jaccard at k          |                                                                      |                                                                                              |
|                       | Số feature chung trong Top k chia số feature thuộc hợp của hai Top k |                                                                                              |
|                       |                                                                      | Đo trùng tập feature. 0 là không trùng, 1 là trùng hoàn toàn.                                |
| Spearman              |                                                                      |                                                                                              |
|                       | Tương quan thứ hạng, chỉ trên feature chung                          |                                                                                              |
|                       |                                                                      | Đo thứ tự tương đối khi có ít nhất hai feature chung. Không có nghĩa hai thang đo bằng nhau. |
| Signed agreement      |                                                                      |                                                                                              |
|                       | Tỷ lệ feature chung có cùng dấu                                      |                                                                                              |
|                       |                                                                      | Chỉ là chỉ số phụ: SHAP dùng raw margin còn LIME fit theo xác suất.                          |
| Domain Precision at 5 |                                                                      |                                                                                              |

|                      |                                                                        |                                                                                                            |
|----------------------|------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------|
|                      | Số feature Top 5 khớp expected signals chia 5                          |                                                                                                            |
|                      |                                                                        | Đối chiếu có cấu trúc với kiến thức miền; không phải điểm đúng từ chuyên gia SOC.                          |
| Local R <sup>2</sup> |                                                                        |                                                                                                            |
|                      | R <sup>2</sup> của Ridge surrogate LIME quanh một flow                 |                                                                                                            |
|                      |                                                                        | Đo LIME bắt chước XGBoost tốt hay kém. Đây là chỉ số chất lượng cốt lõi của LIME.                          |
| Faithfulness         |                                                                        |                                                                                                            |
|                      | Top k làm giảm score lớp gốc mạnh hơn random khi thay bằng donor train |                                                                                                            |
|                      |                                                                        | Đo ảnh hưởng tương đối lên model trong protocol donor substitution; không chứng minh nhân quả ngoài model. |

## 4 Ket qua Sub RQ 2 1 Tuong dong SHAP LIME

SHAP và LIME được ghép theo sample id và feature của cùng 1.339 flow. SHAP xếp hạng theo absolute SHAP value; LIME xếp hạng theo absolute weight. Kết quả macro là trung bình không trọng số của 15 lớp.

| k  | Jaccard macro | Spearman macro | Signed agreement macro | Kết luận                                                                   |
|----|---------------|----------------|------------------------|----------------------------------------------------------------------------|
| 3  |               |                |                        |                                                                            |
|    | 0,241         |                |                        |                                                                            |
|    |               | 0,818          |                        |                                                                            |
|    |               |                | 0,959                  |                                                                            |
|    |               |                |                        | Có ít feature chung, nhưng thứ tự và chiều của feature chung khá gần nhau. |
| 5  |               |                |                        |                                                                            |
|    | 0,213         |                |                        |                                                                            |
|    |               | 0,476          |                        |                                                                            |
|    |               |                | 0,896                  |                                                                            |
|    |               |                |                        | Top 5 trùng lặp thấp - trung bình. Đây là mức dùng làm kết luận chính.     |
| 10 |               |                |                        |                                                                            |
|    | 0,239         |                |                        |                                                                            |
|    |               | 0,380          |                        |                                                                            |
|    |               |                | 0,847                  |                                                                            |
|    |               |                |                        | Mở rộng danh sách không làm hai phương pháp hội tụ đáng kể.                |

| Lớp | N | Jaccard at 5 | Spearman | Cùng dấu |
|-----|---|--------------|----------|----------|
|-----|---|--------------|----------|----------|

|                        |     |       |        |       |
|------------------------|-----|-------|--------|-------|
| Benign                 |     |       |        |       |
|                        | 100 |       |        |       |
|                        |     | 0.091 |        |       |
|                        |     |       | -0.375 |       |
|                        |     |       |        | 0.782 |
| Bot                    |     |       |        |       |
|                        | 100 |       |        |       |
|                        |     | 0.273 |        |       |
|                        |     |       | 0.805  |       |
|                        |     |       |        | 0.960 |
| Brute Force -Web       |     |       |        |       |
|                        | 86  |       |        |       |
|                        |     | 0.166 |        |       |
|                        |     |       | -0.148 |       |
|                        |     |       |        | 1.000 |
| Brute Force -XSS       |     |       |        |       |
|                        | 44  |       |        |       |
|                        |     | 0.105 |        |       |
|                        |     |       | -0.333 |       |
|                        |     |       |        | 0.985 |
| DDOS attack-HOIC       |     |       |        |       |
|                        | 100 |       |        |       |
|                        |     | 0.355 |        |       |
|                        |     |       | 0.992  |       |
|                        |     |       |        | 1.000 |
| DDOS attack-LOIC-UDP   |     |       |        |       |
|                        | 100 |       |        |       |
|                        |     | 0.361 |        |       |
|                        |     |       | 0.976  |       |
|                        |     |       |        | 0.938 |
| DDoS attacks-LOIC-HTTP |     |       |        |       |
|                        | 100 |       |        |       |

|                          |     |       |        |       |
|--------------------------|-----|-------|--------|-------|
|                          |     | 0.341 |        |       |
|                          |     |       | -0.420 |       |
|                          |     |       |        | 0.681 |
| DoS attacks-GoldenEye    |     |       |        |       |
|                          | 100 |       |        |       |
|                          |     | 0.257 |        |       |
|                          |     |       | 0.982  |       |
|                          |     |       |        | 1.000 |
| DoS attacks-Hulk         |     |       |        |       |
|                          | 100 |       |        |       |
|                          |     | 0.156 |        |       |
|                          |     |       | 1.000  |       |
|                          |     |       |        | 1.000 |
| DoS attacks-SlowHTTPTest |     |       |        |       |
|                          | 100 |       |        |       |
|                          |     | 0.215 |        |       |
|                          |     |       | 0.976  |       |
|                          |     |       |        | 0.955 |
| DoS attacks-Slowloris    |     |       |        |       |
|                          | 100 |       |        |       |
|                          |     | 0.175 |        |       |
|                          |     |       | 0.727  |       |
|                          |     |       |        | 1.000 |
| FTP-BruteForce           |     |       |        |       |
|                          | 100 |       |        |       |
|                          |     | 0.185 |        |       |
|                          |     |       | 0.955  |       |
|                          |     |       |        | 0.912 |
| Infiltration             |     |       |        |       |
|                          | 100 |       |        |       |
|                          |     | 0.043 |        |       |
|                          |     |       | 0.000  |       |

|                |     |       |       |       |
|----------------|-----|-------|-------|-------|
|                |     |       |       | 0.333 |
| SQL Injection  |     |       |       |       |
|                | 9   |       |       |       |
|                |     | 0.000 |       |       |
|                |     |       | NA    |       |
|                |     |       |       | NA    |
| SSH-Bruteforce |     |       |       |       |
|                | 100 |       |       |       |
|                |     | 0.480 |       |       |
|                |     |       | 0.529 |       |
|                |     |       |       | 1.000 |

SSH Bruteforce có Jaccard at 5 cao nhất (0,480), trong khi SQL Injection bằng 0 và không đủ feature chung để tính Spearman. Vì SQL Injection chỉ có 9 flow, không được suy rộng riêng kết quả lớp này thành kết luận toàn bộ phương pháp.

## 5 Kết quả Sub RQ 2.2 Đo lường kiến thức miền

Expected signals được xác định trước theo cơ chế của từng loại tấn công. Vì cohort chính chỉ gồm dự đoán đúng, true label bằng predicted label; nhờ đó việc so với expected signals theo lớp là nhất quán.

| Phương pháp | Macro Domain Precision at 5 | Diễn giải                                                                           |
|-------------|-----------------------------|-------------------------------------------------------------------------------------|
| SHAP        |                             |                                                                                     |
|             | 0,187                       |                                                                                     |
|             |                             | Khoảng 18,7 phần trăm feature Top 5 khớp bằng expected signals theo trung bình lớp. |
| LIME        |                             |                                                                                     |
|             | 0,111                       |                                                                                     |
|             |                             | Khoảng 11,1 phần trăm; thấp hơn SHAP trong cùng điều kiện.                          |

| Lớp    | N   | SHAP Precision at 5 | LIME Precision at 5 |
|--------|-----|---------------------|---------------------|
| Benign |     |                     |                     |
|        | 100 |                     |                     |
|        |     | 0.202               |                     |
|        |     |                     | 0.096               |
| Bot    |     |                     |                     |
|        | 100 |                     |                     |

|                          |     |       |       |
|--------------------------|-----|-------|-------|
|                          |     | 0.200 |       |
|                          |     |       | 0.204 |
| Brute Force -Web         |     |       |       |
|                          | 86  |       |       |
|                          |     | 0.216 |       |
|                          |     |       | 0.116 |
| Brute Force -XSS         |     |       |       |
|                          | 44  |       |       |
|                          |     | 0.377 |       |
|                          |     |       | 0.064 |
| DDOS attack-HOIC         |     |       |       |
|                          | 100 |       |       |
|                          |     | 0.008 |       |
|                          |     |       | 0.034 |
| DDOS attack-LOIC-UDP     |     |       |       |
|                          | 100 |       |       |
|                          |     | 0.072 |       |
|                          |     |       | 0.198 |
| DDoS attacks-LOIC-HTTP   |     |       |       |
|                          | 100 |       |       |
|                          |     | 0.312 |       |
|                          |     |       | 0.230 |
| DoS attacks-GoldenEye    |     |       |       |
|                          | 100 |       |       |
|                          |     | 0.140 |       |
|                          |     |       | 0.070 |
| DoS attacks-Hulk         |     |       |       |
|                          | 100 |       |       |
|                          |     | 0.000 |       |
|                          |     |       | 0.178 |
| DoS attacks-SlowHTTPTest |     |       |       |
|                          | 100 |       |       |

|                       |     |       |       |
|-----------------------|-----|-------|-------|
|                       |     | 0.278 |       |
|                       |     |       | 0.064 |
| DoS attacks-Slowloris |     |       |       |
|                       | 100 |       |       |
|                       |     | 0.008 |       |
|                       |     |       | 0.024 |
| FTP-BruteForce        |     |       |       |
|                       | 100 |       |       |
|                       |     | 0.212 |       |
|                       |     |       | 0.056 |
| Infiltration          |     |       |       |
|                       | 100 |       |       |
|                       |     | 0.198 |       |
|                       |     |       | 0.008 |
| SQL Injection         |     |       |       |
|                       | 9   |       |       |
|                       |     | 0.244 |       |
|                       |     |       | 0.089 |
| SSH-Bruteforce        |     |       |       |
|                       | 100 |       |       |
|                       |     | 0.332 |       |
|                       |     |       | 0.228 |

Giá trị thấp không chứng minh model hoặc SHAP và LIME “sai”. CICFlowMeter chứa thống kê flow, trong khi tín hiệu chuyên gia có thể cần payload HTTP, log web, log xác thực hoặc PCAP. Đây là giới hạn của dữ liệu và bộ expected signals đơn giản hóa. Vì chưa có chấm điểm SOC độc lập, không gọi Domain Precision là “tỷ lệ giải thích đúng”.


## 6 Kết quả Sub RQ 2.3 Chất lượng và độ ổn định của LIME

LIME sinh các sample lân cận rồi fit Ridge regression. Nếu Ridge không tái tạo được hành vi XGBoost quanh flow, các feature ranking chỉ là xấp xỉ yếu. Do đó Local  $R^2$  cần được đọc trước khi sử dụng Top 5 LIME.

| Chẩn đoán Local $R^2$ trên 60 flow     | Median $R^2$ | Mean $R^2$ | Kết luận |
|----------------------------------------|--------------|------------|----------|
| Baseline 5.000 sample, discretize true |              |            |          |
|                                        | 0,062        |            |          |

|                                |       |       |                  |
|--------------------------------|-------|-------|------------------|
|                                |       | 0,113 |                  |
|                                |       |       | Cấu hình chính.  |
| 10.000 sample                  |       |       |                  |
|                                | 0,048 |       |                  |
|                                |       | 0,102 |                  |
|                                |       |       | Không cải thiện. |
| 5.000 sample, discretize false |       |       |                  |
|                                | 0,029 |       |                  |
|                                |       | 0,115 |                  |
|                                |       |       | Không cải thiện. |


Trên toàn bộ 1.339 flow, Local  $R^2$  median là 0,068 và mean là 0,119, thấp hơn ngưỡng cảnh báo 0,30. Vì vậy, trong các cấu hình đã thử, LIME không tạo được surrogate tuyến tính đủ tốt cho ranh giới phi tuyến của XGBoost trên 78 feature.



Hình 1. Phân bố Local  $R^2$  của LIME theo lớp; đường đỏ là ngưỡng 0,30.

| Stability LIME | Phạm vi                                  | Kết quả                     | Cách hiểu                                                         |
|----------------|------------------------------------------|-----------------------------|-------------------------------------------------------------------|
| Khác seed      |                                          |                             |                                                                   |
|                | 289 flow, tối đa 20 flow mỗi lớp, 8 seed |                             |                                                                   |
|                |                                          | Median Jaccard at 5 = 0,415 |                                                                   |
|                |                                          |                             | Top 5 thay đổi đáng kể giữa các lần chạy. Ổn định mức trung bình. |

|                              |                  |                                            |                                              |
|------------------------------|------------------|--------------------------------------------|----------------------------------------------|
| Nhiều thời gian 1 phần trăm  |                  |                                            |                                              |
|                              | 289 flow, 3 seed |                                            |                                              |
|                              |                  | Jaccard = 0,450; đổi nhãn = 3,00 phần trăm |                                              |
|                              |                  |                                            | Explanation thay đổi nhiều hơn nhãn dự đoán. |
| Nhiều thời gian 5 phần trăm  |                  |                                            |                                              |
|                              | 289 flow, 3 seed |                                            |                                              |
|                              |                  | Jaccard = 0,449; đổi nhãn = 4,15 phần trăm |                                              |
|                              |                  |                                            | Mức giao feature gần như không đổi.          |
| Nhiều thời gian 10 phần trăm |                  |                                            |                                              |
|                              | 289 flow, 3 seed |                                            |                                              |
|                              |                  | Jaccard = 0,448; đổi nhãn = 5,77 phần trăm |                                              |
|                              |                  |                                            | Không suy rộng ngoài tập con 289 flow.       |



Hình 2. Robustness của LIME trước nhiều thời gian trên tập con 289 flow.

## 7 Kết quả Sub RQ 2 4 Faithfulness ghép cặp


Hai phương pháp dùng cùng protocol donor substitution: giữ cố định lớp dự đoán ban đầu; chọn Top k feature đóng góp dương; thay giá trị bằng 10 donor từ train set với seed 173; so với 20 random controls dùng seed 2026. "Win" nghĩa là mức giảm raw margin của tập feature được chọn lớn hơn random quá 10 mũ trừ 6.

| Phương | k | N | Đủ ĐK | Coverage | Win rate | Margin drop | Margin drop |
|--------|---|---|-------|----------|----------|-------------|-------------|
|--------|---|---|-------|----------|----------|-------------|-------------|

| pháp |   |      |      |         |        | method | random |
|------|---|------|------|---------|--------|--------|--------|
| LIME |   |      |      |         |        |        |        |
|      | 3 |      |      |         |        |        |        |
|      |   | 1339 |      |         |        |        |        |
|      |   |      | 1339 |         |        |        |        |
|      |   |      |      | 100.00% |        |        |        |
|      |   |      |      |         | 82.60% |        |        |
|      |   |      |      |         |        | 7.687  |        |
|      |   |      |      |         |        |        | 1.064  |
| SHAP |   |      |      |         |        |        |        |
|      | 3 |      |      |         |        |        |        |
|      |   | 1339 |      |         |        |        |        |
|      |   |      | 1339 |         |        |        |        |
|      |   |      |      | 100.00% |        |        |        |
|      |   |      |      |         | 98.88% |        |        |
|      |   |      |      |         |        | 9.960  |        |
|      |   |      |      |         |        |        | 3.250  |
| LIME |   |      |      |         |        |        |        |
|      | 5 |      |      |         |        |        |        |
|      |   | 1339 |      |         |        |        |        |
|      |   |      | 1339 |         |        |        |        |
|      |   |      |      | 100.00% |        |        |        |
|      |   |      |      |         | 90.44% |        |        |
|      |   |      |      |         |        | 8.071  |        |
|      |   |      |      |         |        |        | 1.724  |
| SHAP |   |      |      |         |        |        |        |
|      | 5 |      |      |         |        |        |        |
|      |   | 1339 |      |         |        |        |        |
|      |   |      | 1339 |         |        |        |        |
|      |   |      |      | 100.00% |        |        |        |
|      |   |      |      |         | 95.74% |        |        |
|      |   |      |      |         |        | 10.875 |        |
|      |   |      |      |         |        |        | 4.974  |

|      |    |      |      |         |        |        |       |
|------|----|------|------|---------|--------|--------|-------|
| LIME |    |      |      |         |        |        |       |
|      | 10 |      |      |         |        |        |       |
|      |    | 1339 |      |         |        |        |       |
|      |    |      | 1339 |         |        |        |       |
|      |    |      |      | 100.00% |        |        |       |
|      |    |      |      |         | 94.77% |        |       |
|      |    |      |      |         |        | 8.806  |       |
|      |    |      |      |         |        |        | 3.270 |
| SHAP |    |      |      |         |        |        |       |
|      | 10 |      |      |         |        |        |       |
|      |    | 1339 |      |         |        |        |       |
|      |    |      | 1076 |         |        |        |       |
|      |    |      |      | 80.36%  |        |        |       |
|      |    |      |      |         | 99.81% |        |       |
|      |    |      |      |         |        | 11.522 |       |
|      |    |      |      |         |        |        | 6.805 |

Ở  $k = 5$ , SHAP thắng đối chứng ngẫu nhiên ở 95,74 phần trăm flow đủ điều kiện, trong khi LIME đạt 90,44 phần trăm. SHAP cao hơn LIME ở cả  $k = 3, 5$  và  $10$ . Với SHAP  $k = 10$ , coverage chỉ 80,36 phần trăm nên không được so sánh với  $k$  khác mà bỏ qua coverage.



Hình 3. Faithfulness win rate của SHAP và LIME trên cùng cohort 1.339 flow.

Kết quả này khác với SHAP faithfulness 99,31 phần trăm trên toàn bộ 700.000 test flow trước đó. 99,31 phần trăm chỉ là bằng chứng global bổ sung cho SHAP, không thay thế và không được gộp với phép so sánh ghép cặp 1.339 flow trong RQ2.

### 8 Doi chieu Top feature theo lop

Top feature không phải một danh sách chung cho tất cả flow. Với LIME, bảng sau là mean absolute LIME weight trên cohort dự đoán đúng. Với SHAP, Top 1 ở cột bên phải là kết quả global trên test set của các lớp tấn công; hai phạm vi khác nhau nên chỉ dùng để tham khảo, không tính agreement từ bảng này.

| Lớp                    | Top 1 LIME cohort 1.339 | Top 1 SHAP global         |
|------------------------|-------------------------|---------------------------|
| Benign                 |                         |                           |
|                        | FIN Flag Cnt            |                           |
|                        |                         | Không có CSV global riêng |
| Bot                    |                         |                           |
|                        | Dst Port                |                           |
|                        |                         | Dst Port                  |
| Brute Force -Web       |                         |                           |
|                        | RST Flag Cnt            |                           |
|                        |                         | Fwd Pkt Len Mean          |
| Brute Force -XSS       |                         |                           |
|                        | Bwd Pkts/s              |                           |
|                        |                         | Init Fwd Win Byts         |
| DDOS attack-HOIC       |                         |                           |
|                        | Init Fwd Win Byts       |                           |
|                        |                         | Init Fwd Win Byts         |
| DDOS attack-LOIC-UDP   |                         |                           |
|                        | Tot Fwd Pkts            |                           |
|                        |                         | Tot Fwd Pkts              |
| DDoS attacks-LOIC-HTTP |                         |                           |
|                        | Fwd Pkts/s              |                           |
|                        |                         | Fwd Pkts/s                |
| DoS attacks-GoldenEye  |                         |                           |
|                        | Fwd Seg Size Min        |                           |
|                        |                         | Fwd Seg Size Min          |
| DoS attacks-Hulk       |                         |                           |

|                          |                  |                   |
|--------------------------|------------------|-------------------|
|                          | FIN Flag Cnt     |                   |
|                          |                  | Fwd Seg Size Min  |
| DoS attacks-SlowHTTPTest |                  |                   |
|                          | Fwd Seg Size Min |                   |
|                          |                  | Fwd Seg Size Min  |
| DoS attacks-Slowloris    |                  |                   |
|                          | FIN Flag Cnt     |                   |
|                          |                  | Bwd IAT Max       |
| FTP-BruteForce           |                  |                   |
|                          | Fwd Seg Size Min |                   |
|                          |                  | Fwd Seg Size Min  |
| Infiltration             |                  |                   |
|                          | Fwd URG Flags    |                   |
|                          |                  | Fwd Header Len    |
| SQL Injection            |                  |                   |
|                          | Bwd IAT Std      |                   |
|                          |                  | Init Fwd Win Byts |
| SSH-Bruteforce           |                  |                   |
|                          | Dst Port         |                   |
|                          |                  | Dst Port          |

Ví dụ, SSH BruteForce có Dst Port nổi bật ở cả hai phạm vi; LOIC UDP có Tot Fwd Pkts ở cả hai. Nhưng tương đồng tại một lớp không phủ định kết quả Jaccard per-flow thấp: phân tích RQ2 phải ưu tiên metric per-flow đã ghép cặp.

## 9 Tra loi tong hop RQ2

Trên dữ liệu CSE CIC IDS2018 và XGBoost đã khóa từ RQ1, SHAP là lựa chọn phù hợp hơn để làm lời giải thích chính cho RQ2. Trong cohort ghép cặp 1.339 flow, SHAP có Domain Precision at 5 cao hơn LIME (0,187 so với 0,111) và faithfulness win rate cao hơn ở  $k = 3, 5, 10$ . LIME không đồng thuận mạnh với SHAP ở Top 5 (Jaccard 0,213) và Local  $R^2$  thấp cho thấy surrogate tuyến tính cục bộ chưa mô tả tốt model nền. Vì vậy, LIME đóng vai trò phép đối chứng và bằng chứng về giới hạn của local surrogate, không dùng để thay thế SHAP.

Phát biểu này là có điều kiện theo dataset, model, cohort và protocol đã nêu. Nó không khẳng định SHAP là lời giải thích nhân quả của hành vi tấn công, không khẳng định mọi feature Top 5 là dấu hiệu tấn công thực tế, và không thay thế validation bằng PCAP, payload hoặc đánh giá chuyên gia SOC.

## 10 Giới hạn và hướng hoàn thiện tiếp theo

- SQL Injection có 9 flow và Brute Force XSS có 44 flow trong cohort. Chỉ báo cáo mô tả cho các lớp hiếm, không đưa kết luận thống kê mạnh riêng theo lớp.
- Domain signals là bộ kỳ vọng dựa trên cơ chế tấn công. Để tăng tính thuyết phục, có thể có hai người đánh giá SOC độc lập, định nghĩa rubric trước và đo mức đồng thuận.
- Donor substitution có thể tạo mẫu ngoài phân phối do ghép feature từ flow train sang flow test. Faithfulness hiện là ảnh hưởng tương đối trong protocol này, không phải nhân quả.
- Nếu triển khai RQ3 realtime, dùng SHAP cho cảnh báo quan trọng hoặc batch review. Không dùng Local  $R^2$  thấp của LIME như bằng chứng chính cho analyst.

## Phụ lục Nguồn bằng chứng và code

| Nhóm    | Nguồn đã đối chiếu                                                                     | Vai trò trong báo cáo                                                       |
|---------|----------------------------------------------------------------------------------------|-----------------------------------------------------------------------------|
| SHAP    |                                                                                        |                                                                             |
|         | Bao_cao_RQ_SHAP_XGBoost.docx; build_cohort_and_shap.py                                 |                                                                             |
|         |                                                                                        | Kết quả SHAP global, cohort per-flow, cấu hình TreeExplainer và additivity. |
| LIME    |                                                                                        |                                                                             |
|         | RQ2_LIME_Ket_Qua_Final.docx;<br>RQ2_LIME_Bao_Cao_Rieng.docx; run_lime_paired_cohort.py |                                                                             |
|         |                                                                                        | Cấu hình LIME, Local $R^2$ , Top feature, stability và robustness.          |
| So sánh |                                                                                        |                                                                             |
|         | evaluate_agreement.py; evaluate_domain.py;<br>paired_faithfulness.py                   |                                                                             |
|         |                                                                                        | Định nghĩa phép đo và CSV summary trên cohort ghép cặp.                     |

Các script kiểm tra sample id, số feature và predicted label trước khi ghép dữ liệu. SHAP kiểm tra additivity với raw margin. Đây là các điều kiện cần để so sánh per-flow có ý nghĩa.