

Bao cao hoan chinh RQ2 SHAP LIME

Đánh giá chất lượng lời giải thích của XGBoost trên CSE CIC IDS2018

Kết luận chính của RQ2 là: trên cohort ghép cặp 1.339 flow, SHAP và LIME không thường xuyên chọn cùng Top 5 feature; SHAP có Domain Precision và faithfulness cao hơn LIME trong các phép đo đã chọn. LIME chạy đúng quy trình nhưng Local R^2 thấp, nên chỉ được dùng như phương pháp đối chứng cục bộ chứ không phải căn cứ chính để kết luận nguyên nhân dự đoán của XGBoost.

1 Cau hoi nghien cuu va cau tra loi

Sub RQ	Câu hỏi	Kết quả chính
2.1	SHAP và LIME có chọn các feature giống nhau không?	Jaccard at 5 = 0,213. Mức giống nhau Top 5 thấp - trung bình.
2.2	Feature quan trọng có phù hợp tín hiệu được kỳ vọng theo cơ chế tấn công không?	Domain Precision at 5: SHAP = 0,187; LIME = 0,111. Cả hai thấp.
2.3	Lời giải thích có ổn định và bền vững không?	LIME: Local R^2 median = 0,068; stability median Jaccard at 5 = 0,415.
2.4	Feature được chọn có thực sự ảnh hưởng đến quyết định model không?	Faithfulness at k = 5: SHAP = 95,74%; LIME = 90,44%.

Bốn chỉ số trên đo bốn khía cạnh khác nhau. Không được cộng, trung bình hay diễn giải chúng thành một tỷ lệ duy nhất như "RQ2 đúng X phần trăm".

2 Phạm vi và tình tại lap

Báo cáo hợp nhất ba nhóm bằng chứng: (i) SHAP global đã tính trên toàn bộ test set 700.000 flow, (ii) SHAP per-flow và LIME per-flow trên cohort ghép cặp, và (iii) các script đánh giá agreement, domain, stability robustness và faithfulness. Các so sánh trực tiếp SHAP - LIME chỉ dùng cohort ghép cặp.

Thành phần	Thiết lập đã khóa	Lý do
Model	XGBoost 15 lớp, 100 cây, max depth 8, learning rate 0,08, 78 feature	Cùng model đã chọn trong RQ1.
Cohort ghép cặp	1.339 flow dự đoán đúng, seed 42, tối đa 100 flow mỗi lớp	Đảm bảo SHAP và LIME giải thích đúng cùng sample và cùng output.
Lớp hiếm	Brute Force XSS: 44 flow; SQL Injection: 9 flow	Giữ toàn bộ flow đúng có sẵn. Kết luận theo hai lớp này chỉ có tính minh họa.
SHAP	TreeExplainer, raw margin, tree path dependent, không approximate	Phù hợp trực tiếp với XGBoost; kiểm tra additivity.
LIME	Background 8.002 flow; 5.000 sample per flow; kernel width 6,624; discretize continuous	Fit Ridge surrogate cục bộ để giải thích predicted label.

Cohort chỉ giữ flow dự đoán đúng để đối chiếu knowledge domain theo nhãn lớp không bị lẫn với lỗi dự đoán. Điều này không có nghĩa model không cần giải thích flow sai. Error cohort tồn tại để làm case study riêng, nhưng không được trộn vào trung bình chính của RQ2.

3 Phương pháp và các chỉ số

Chỉ số	Công thức hoặc ý tưởng	Cách diễn giải đúng
Jaccard at k	Số feature chung trong Top k chia số feature thuộc hợp của hai Top k	Đo trùng tập feature. 0 là không trùng, 1 là trùng hoàn toàn.
Spearman	Tương quan thứ hạng, chỉ trên feature chung	Đo thứ tự tương đối khi có ít nhất hai feature chung. Không có nghĩa hai thang đo bằng nhau.
Signed agreement	Tỷ lệ feature chung có cùng dấu	Chỉ là chỉ số phụ: SHAP dùng raw margin còn LIME fit theo xác suất.
Domain Precision at 5	Số feature Top 5 khớp expected signals chia 5	Đối chiếu có cấu trúc với kiến thức miền; không phải điểm đúng từ chuyên gia SOC.
Local R ²	R ² của Ridge surrogate LIME quanh một flow	Đo LIME bắt chước XGBoost tốt hay kém. Đây là chỉ số chất lượng cốt lõi của LIME.
Faithfulness	Top k làm giảm score lớp gốc mạnh hơn random khi thay bằng donor train	Đo ảnh hưởng tương đối lên model trong protocol donor substitution; không chứng minh nhân quả ngoài model.

4 Kết quả Sub RQ 2 1 Tương đồng SHAP LIME

SHAP và LIME được ghép theo sample id và feature của cùng 1.339 flow. SHAP xếp hạng theo absolute SHAP value; LIME xếp hạng theo absolute weight. Kết quả macro là trung bình không trọng số của 15 lớp.

k	Jaccard macro	Spearman macro	Signed agreement macro	Kết luận
3	0,241	0,818	0,959	Có ít feature chung, nhưng thứ tự và chiều của feature chung khá gần nhau.
5	0,213	0,476	0,896	Top 5 trùng lặp thấp - trung bình. Đây là mức dùng làm kết luận chính.
10	0,239	0,380	0,847	Mở rộng danh sách không làm hai phương pháp hội tụ đáng kể.

Lớp	N	Jaccard at 5	Spearman	Cùng dấu
Benign	100	0.091	-0.375	0.782
Bot	100	0.273	0.805	0.960
Brute Force -Web	86	0.166	-0.148	1.000
Brute Force -XSS	44	0.105	-0.333	0.985
DDOS attack-HOIC	100	0.355	0.992	1.000
DDOS attack-LOIC-UDP	100	0.361	0.976	0.938
DDoS attacks-LOIC-HTTP	100	0.341	-0.420	0.681
DoS attacks-GoldenEye	100	0.257	0.982	1.000
DoS attacks-Hulk	100	0.156	1.000	1.000
DoS attacks-SlowHTTPTest	100	0.215	0.976	0.955
DoS attacks-Slowloris	100	0.175	0.727	1.000
FTP-BruteForce	100	0.185	0.955	0.912
Infiltration	100	0.043	0.000	0.333
SQL Injection	9	0.000	NA	NA
SSH-Bruteforce	100	0.480	0.529	1.000

SSH BruteForce có Jaccard at 5 cao nhất (0,480), trong khi SQL Injection bằng 0 và không đủ feature chung để tính Spearman. Vì SQL Injection chỉ có 9 flow, không được suy rộng riêng kết quả lớp này thành kết luận toàn bộ phương pháp.

5 Ket qua Sub RQ 2 2 Doi chieu kien thuc mien

Expected signals được xác định trước theo cơ chế của từng loại tấn công. Vì cohort chính chỉ gồm dự đoán đúng, true label bằng predicted label; nhờ đó việc so với expected signals theo lớp là nhất quán.

Phương pháp	Macro Domain Precision at 5	Diễn giải
SHAP	0,187	Khoảng 18,7 phần trăm feature Top 5 khớp bằng expected signals theo trung bình lớp.
LIME	0,111	Khoảng 11,1 phần trăm; thấp hơn SHAP trong cùng điều kiện.

Lớp	N	SHAP Precision at 5	LIME Precision at 5
Benign	100	0.202	0.096
Bot	100	0.200	0.204
Brute Force -Web	86	0.216	0.116
Brute Force -XSS	44	0.377	0.064
DDOS attack-HOIC	100	0.008	0.034
DDOS attack-LOIC-UDP	100	0.072	0.198
DDoS attacks-LOIC-HTTP	100	0.312	0.230
DoS attacks-GoldenEye	100	0.140	0.070
DoS attacks-Hulk	100	0.000	0.178
DoS attacks-SlowHTTPTest	100	0.278	0.064
DoS attacks-Slowloris	100	0.008	0.024
FTP-BruteForce	100	0.212	0.056
Infiltration	100	0.198	0.008
SQL Injection	9	0.244	0.089
SSH-Bruteforce	100	0.332	0.228


Giá trị thấp không chứng minh model hoặc SHAP và LIME “sai”. CICFlowMeter chứa thống kê flow, trong khi tín hiệu chuyên gia có thể cần payload HTTP, log web, log xác thực hoặc PCAP. Đây là giới hạn của dữ liệu và bộ expected signals đơn giản hóa. Vì chưa có chấm điểm SOC độc lập, không gọi Domain Precision là “tỷ lệ giải thích đúng”.

6 Ket qua Sub RQ 2 3 Chat luong va do on dinh cua LIME

LIME sinh các sample lân cận rồi fit Ridge regression. Nếu Ridge không tái tạo được hành vi XGBoost quanh flow, các feature ranking chỉ là xấp xỉ yếu. Do đó Local R² cần được đọc trước khi sử dụng Top 5 LIME.


Chẩn đoán Local R ² trên 60 flow	Median R ²	Mean R ²	Kết luận
Baseline 5.000 sample, discretize true	0,062	0,113	Cấu hình chính.
10.000 sample	0,048	0,102	Không cải thiện.
5.000 sample, discretize false	0,029	0,115	Không cải thiện.

Trên toàn bộ 1.339 flow, Local R^2 median là 0,068 và mean là 0,119, thấp hơn ngưỡng cảnh báo 0,30. Vì vậy, trong các cấu hình đã thử, LIME không tạo được surrogate tuyến tính đủ tốt cho ranh giới phi tuyến của XGBoost trên 78 feature.



Hình 1. Phân bố Local R^2 của LIME theo lớp; đường đỏ là ngưỡng 0,30.

Stability LIME	Phạm vi	Kết quả	Cách hiểu
Khác seed	289 flow, tối đa 20 flow mỗi lớp, 8 seed	Median Jaccard at 5 = 0,415	Top 5 thay đổi đáng kể giữa các lần chạy. Ổn định mức trung bình.
Nhiều thời gian 1 phần trăm	289 flow, 3 seed	Jaccard = 0,450; đổi nhãn = 3,00 phần trăm	Explanation thay đổi nhiều hơn nhãn dự đoán.
Nhiều thời gian 5 phần trăm	289 flow, 3 seed	Jaccard = 0,449; đổi nhãn = 4,15 phần trăm	Mức giao feature gần như không đổi.
Nhiều thời gian 10 phần trăm	289 flow, 3 seed	Jaccard = 0,448; đổi nhãn = 5,77 phần trăm	Không suy rộng ngoài tập con 289 flow.




Hình 2. Robustness của LIME trước nhiều thời gian trên tập con 289 flow.

7 Ket qua Sub RQ 2 4 Faithfulness ghép cap

Hai phương pháp dùng cùng protocol donor substitution: giữ cố định lớp dự đoán ban đầu; chọn Top k feature đóng góp dương; thay giá trị bằng 10 donor từ train set với seed 173; so với 20 random controls dùng seed 2026. “Win” nghĩa là mức giảm raw margin của tập feature được chọn lớn hơn random quá 10 mũ trừ 6.

Phương pháp	k	N	Đủ ĐK	Coverage	Win rate	Margin drop method	Margin drop random
LIME	3	1339	1339	100.00%	82.60%	7.687	1.064
SHAP	3	1339	1339	100.00%	98.88%	9.960	3.250
LIME	5	1339	1339	100.00%	90.44%	8.071	1.724
SHAP	5	1339	1339	100.00%	95.74%	10.875	4.974
LIME	10	1339	1339	100.00%	94.77%	8.806	3.270
SHAP	10	1339	1076	80.36%	99.81%	11.522	6.805

Ở k = 5, SHAP thắng đối chứng ngẫu nhiên ở 95,74 phần trăm flow đủ điều kiện, trong khi LIME đạt 90,44 phần trăm. SHAP cao hơn LIME ở cả k = 3, 5 và 10. Với SHAP k = 10, coverage chỉ 80,36 phần trăm nên không được so sánh với k khác mà bỏ qua coverage.



Hình 3. Faithfulness win rate của SHAP và LIME trên cùng cohort 1.339 flow.

Kết quả này khác với SHAP faithfulness 99,31 phần trăm trên toàn bộ 700.000 test flow trước đó. 99,31 phần trăm chỉ là bằng chứng global bổ sung cho SHAP, không thay thế và không được gộp với phép so sánh ghép cặp 1.339 flow trong RQ2.

8 Đo chiều Top feature theo lớp

Top feature không phải một danh sách chung cho tất cả flow. Bảng dưới dùng đúng cùng cohort ghép cặp 1.339 flow cho cả hai phương pháp. Mỗi cột là feature có mean absolute attribution lớn nhất trong các flow dự đoán đúng của từng lớp. Vì vậy bảng có đủ cả 15 lớp, gồm Benign, và không trộn kết quả global với kết quả cohort.

Lớp	Top 1 LIME cohort 1.339	Top 1 SHAP cohort 1.339
Benign	FIN Flag Cnt	Fwd Pkt Len Max
Bot	Dst Port	Dst Port
Brute Force -Web	RST Flag Cnt	Dst Port
Brute Force -XSS	Bwd Pkts/s	Init Fwd Win Byts
DDOS attack-HOIC	Init Fwd Win Byts	Init Fwd Win Byts
DDOS attack-LOIC-UDP	Tot Fwd Pkts	Tot Fwd Pkts
DDoS attacks-LOIC-HTTP	Fwd Pkts/s	Fwd Pkts/s
DoS attacks-GoldenEye	Fwd Seg Size Min	Fwd Seg Size Min
DoS attacks-Hulk	FIN Flag Cnt	Fwd Seg Size Min
DoS attacks-SlowHTTPTest	Fwd Seg Size Min	Fwd Seg Size Min
DoS attacks-Slowloris	FIN Flag Cnt	Bwd IAT Max
FTP-BruteForce	Fwd Seg Size Min	Fwd Seg Size Min
Infiltration	Fwd URG Flags	Fwd Header Len
SQL Injection	Bwd IAT Std	Bwd Pkt Len Std
SSH-Bruteforce	Dst Port	Dst Port

Ví dụ, Benign có Top 1 SHAP cohort là Fwd Pkt Len Max; SSH BruteForce có Dst Port nổi bật ở cả hai phương pháp. Nhưng tương đồng tại một lớp không phủ định kết quả Jaccard per-flow thấp: RQ2 phải ưu tiên metric per-flow đã ghép cặp.

9 Tra loi tong hop RQ2

Trên dữ liệu CSE CIC IDS2018 và XGBoost đã khóa từ RQ1, SHAP là lựa chọn phù hợp hơn để làm lời giải thích chính cho RQ2. Trong cohort ghép cặp 1.339 flow, SHAP có Domain Precision at 5 cao hơn LIME (0,187 so với 0,111) và faithfulness win rate cao hơn ở $k = 3, 5, 10$. LIME không đồng thuận mạnh với SHAP ở Top 5 (Jaccard 0,213) và Local R^2 thấp cho thấy surrogate tuyến tính cục bộ chưa mô tả tốt model nền. Vì vậy, LIME đóng vai trò phép đối chứng và bằng chứng về giới hạn của local surrogate, không dùng để thay thế SHAP.

Phát biểu này là có điều kiện theo dataset, model, cohort và protocol đã nêu. Nó không khẳng định SHAP là lời giải thích nhân quả của hành vi tấn công, không khẳng định mọi feature Top 5 là dấu hiệu tấn công thực tế, và không thay thế validation bằng PCAP, payload hoặc đánh giá chuyên gia SOC.

10 Gioi han va huong hoan thien tiep theo

- SQL Injection có 9 flow và Brute Force XSS có 44 flow trong cohort. Chỉ báo cáo mô tả cho các lớp hiếm, không đưa kết luận thống kê mạnh riêng theo lớp.
- Domain signals là bộ kỳ vọng dựa trên cơ chế tấn công. Để tăng tính thuyết phục, có thể có hai người đánh giá SOC độc lập, định nghĩa rubric trước và đo mức đồng thuận.
- Donor substitution có thể tạo mẫu ngoài phân phối do ghép feature từ flow train sang flow test. Faithfulness hiện là ảnh hưởng tương đối trong protocol này, không phải nhân quả.
- Nếu triển khai RQ3 realtime, dùng SHAP cho cảnh báo quan trọng hoặc batch review. Không dùng Local R^2 thấp của LIME như bằng chứng chính cho analyst.

Phu luc Nguon bang chung va code

Nhóm	Nguồn đã đối chiếu	Vai trò trong báo cáo
SHAP	Bao_cao_RQ_SHAP_XGBoost.docx; build_cohort_and_shap.py	Kết quả SHAP global, cohort per-flow, cấu hình TreeExplainer và additivity.
LIME	RQ2_LIME_Ket_Qua_Final.docx; RQ2_LIME_Bao_Cao_Rieng.docx; run_lime_paired_cohort.py	Cấu hình LIME, Local R^2 , Top feature, stability và robustness.
So sánh	evaluate_agreement.py; evaluate_domain.py; paired_faithfulness.py	Định nghĩa phép đo và CSV summary trên cohort ghép cặp.

Các script kiểm tra sample id, số feature và predicted label trước khi ghép dữ liệu. SHAP kiểm tra additivity với raw margin. Đây là các điều kiện cần để so sánh per-flow có ý nghĩa.